Residui per blocco nel caso non lineare

REFRACT · Formule e pseudocodice con JVP mascherati

Obiettivo. Decomporre il residuo del donor in contributi per blocco, tutti nello spazio della **rappresentazione finale**. Non sono differenze fra attivazioni intermedie.

1. Decomposizione integrale

Siano f(x; θ) la rappresentazione finale, θ^0 i pesi pretrained e θ^1 quelli fine-tuned. La maschera M_ℓ conserva il blocco ℓ e azzera gli altri; i blocchi sono disgiunti ed esaustivi.

$$\Delta\theta = \theta^1 - \theta^0, \quad D(x) = f(x;\theta^1) - f(x;\theta^0), \quad v_\ell = M_\ell \Delta\theta$$

Si interpola l'intero modello lungo il segmento $\theta(t) = \theta^0 + t\,\Delta\theta$. Per la regola della catena:

$$\frac{d}{dt} f(x;\theta(t)) = J_\theta f(x;\theta(t))\,\Delta\theta$$

$$D_\ell(x) = \int_0^1 J_\theta f(x;\theta^0 + t\Delta\theta)\, v_\ell \, dt, \qquad D(x) = \sum_{\ell=1}^{L} D_\ell(x)$$

L'identità è esatta quando vale il teorema fondamentale del calcolo lungo il percorso, in particolare per modelli lisci. Δθ è costante rispetto a t; il Jacobiano varia. La decomposizione ripartisce le interazioni non lineari e dipende dal percorso scelto.

2. Che cosa inserire nel JVP

Definire $F_x(\theta) = f(x; \theta)$, con input x fisso. A ogni punto t_k e per ogni blocco ℓ:

$$(y_k, g_{\ell,k}) = \mathrm{JVP}(F_x,\ \theta^0 + t_k\Delta\theta,\ M_\ell\Delta\theta)$$

PRIMALS: tutti i parametri interpolati $\theta^0 + t_k\,\Delta\theta$, **senza maschera**. A un dato t_k, il modello è identico per tutti i blocchi.

TANGENTS: Δθ nel blocco selezionato, tensori zero altrove. **Non moltiplicare la direzione per t_k.** La struttura dei tensori deve coincidere con quella dei primals.

RISULTATO: accumulare il secondo output $g_{\ell,k}$, già uguale al prodotto Jacobiano-direzione. Non sottrarre il forward pretrained.

3. Quadratura ai punti medi

$$t_k = \frac{k+1/2}{K}, \quad k = 0, \ldots, K-1, \qquad \widehat{D}_\ell(x) = \frac{1}{K}\sum_{k=0}^{K-1} g_{\ell,k}(x)$$

Usare gli stessi punti per tutti i blocchi. Per linearità del JVP nella direzione, la somma dei JVP mascherati è il JVP globale a ogni punto: il mascheramento non aggiunge approssimazioni matematiche. Restano quadratura ed errore numerico.

4. Pseudocodice operativo

final_features esegue un forward funzionale usando i parametri ricevuti. Il JVP deriva rispetto ai parametri, non rispetto all'input o a t. Il codice segue la convenzione di torch.func.jvp.

```
# theta0, theta1: dizionari nome -> tensore
# block_of[name]: indice del blocco, da 0 a L-1
# fixed_buffers: stato non parametrico comune ai due modelli
model.eval()
delta = {n: theta1[n] - theta0[n] for n in theta0}

def F(params):
    return final_features(params=params, x=x,
                          buffers=fixed_buffers)

base = detach(F(theta0))
D_hat = [zeros_like(base) for ell in range(L)]

for k in range(K):
    t = (k + 0.5) / K

    # PRIMALS: interpola TUTTI i parametri
    theta_t = {n: theta0[n] + t * delta[n] for n in theta0}

    for ell in range(L):
        # TANGENTS: maschera SOLO la direzione; niente t
        v_ell = {
            n: delta[n] if block_of[n] == ell
               else zeros_like(delta[n])
            for n in theta0
        }
        _, g = jvp(F, primals=(theta_t,),
                      tangents=(v_ell,))
        D_hat[ell] += detach(g) / K

D_exact = detach(F(theta1)) - base
err = norm(sum(D_hat) - D_exact) / (norm(D_exact) + eps)
```

5. Assunzioni e controlli

Stato del modello. Disabilitare dropout e aggiornamenti dello stato. I buffer sono assunti fissi e comuni ai due endpoint; eventuali variazioni, ad esempio delle statistiche BatchNorm, vanno trattate separatamente. Includere nella partizione tutti i parametri modificati che influenzano f.

Errore da evitare. Usare $\theta^0 + t\, M_\ell\, \Delta\theta$ nei primals misura l'effetto di aggiornare il solo blocco ℓ. La somma di questi effetti, in generale, non ricostruisce il fine-tuning completo.

Convergenza. Provare K = 4, 8, 16: controllare l'errore relativo sulla somma e la stabilità dei singoli contributi al raddoppio di K. Errori di blocchi diversi possono cancellarsi nella somma. Il costo diretto è KL JVP per batch di calibrazione.

Uso in REFRACT. Fittare il trasporto R^* sul residuo globale esatto, calcolato con due forward; usare poi il contributo integrato del blocco, dopo il trasporto R^*, come target dei predittori per blocco. L'integrazione serve solo durante la costruzione dei target.